



ESCUELA SUPERIOR LA PONTIFICIA – AYACUCHO

Carrera Profesional: Ingeniería de Sistemas de Información
Curso: Investigación e Inteligencia de Negocios

Predicción de la Cantidad de Turistas en Ayacucho Mediante Series Temporales y Regresión Múltiple Aplicando la Metodología CRISP-DM

Integrantes:

- CCALLOCUNTO GUEVARA, Jhan Carlos 100 %
- GALVEZ FERNANDEZ, Harold Jhordi 100 %
- VILLANUEVA LANDA, Joel Jhonatan 90 %
- QUISPE HUAMANI, Johne 100 %
- ASTUDILLO ALARCÓN, María Paz 90 %

Docente:

Ing. Jurado LOPEZ, Jonathan Pedro

Resumen Ejecutivo

El turismo representa uno de los sectores económicos más relevantes de la región Ayacucho, siendo la Semana Santa su evento de mayor convocatoria a nivel nacional. Sin embargo, la gestión turística regional enfrenta limitaciones en la planificación estratégica debido a la ausencia de modelos analíticos que permitan anticipar la demanda de visitantes.

Problema de investigación. Las instituciones encargadas de la gestión turística en Ayacucho carecen de un modelo cuantitativo que permita predecir con precisión la cantidad mensual de turistas esperados, lo cual genera ineficiencias operativas en la oferta hotelera, el transporte y los servicios complementarios.

Metodología. Se aplicó la metodología CRISP-DM (*Cross Industry Standard Process for Data Mining*) en sus seis fases. Se construyó un conjunto de datos mensuales del período 2010–2024 (180 observaciones) a partir de fuentes oficiales: Ministerio de Comercio Exterior y Turismo (MINCETUR), Instituto Nacional de Estadística e Informática (INEI) y Servicio Nacional de Meteorología e Hidrología (SENAMHI). Se incorporaron variables explicativas como el mes del año, la Semana Santa, el clima, los eventos culturales y la pandemia COVID-19.

Técnicas analíticas empleadas. Se aplicaron dos técnicas complementarias, implementadas en Python con las librerías `statsmodels` y `scikit-learn`: (i) un modelo SARIMA(1,1,1)(1,1,1)₁₂ para el análisis de series temporales, y (ii) un modelo de regresión lineal múltiple para identificar el impacto individual de cada variable explicativa.

Resultados principales. El modelo SARIMA demostró un desempeño superior con un RMSE de 9,446 arribos, MAE de 7,369, MAPE del 18,61 % y R^2 de 0,164, superando a la regresión múltiple en todas las métricas evaluadas. La cuantificación de los coeficientes reveló que la Semana Santa incrementa los arribos en aproximadamente 5,875 visitantes respecto a un mes promedio, mientras que la pandemia produjo una caída media de 21,257 arribos mensuales. El pronóstico para el año 2025 estima un total de 578,069 arribos, con un pico de 62,995 en abril coincidente con la Semana Santa.

Conclusiones. La estacionalidad intrínseca constituye el predictor más robusto del flujo turístico en Ayacucho. Los resultados obtenidos contribuyen a la planificación anticipada de recursos, servicios y promoción turística por parte de la Dirección Regional de Comercio Exterior y Turismo (DIRCETUR) y de los operadores privados del sector. Se cumple el criterio de éxito establecido ($\text{MAPE} < 20\%$) y se entregan pronósticos mensuales accionables para la toma de decisiones en la gestión turística regional.

Palabras clave: predicción turística, series temporales, SARIMA, regresión múltiple, CRISP-DM, Ayacucho, inteligencia de negocios.

Predicción de la Cantidad de Turistas en Ayacucho Mediante Series Temporales y Regresión Múltiple Aplicando la Metodología CRISP-DM

Estudiantes de Ingeniería de Sistemas de Información
Escuela Superior La Pontificia
Ayacucho, Perú
Curso: Investigación e Inteligencia de Negocios

Resumen—Problema: El turismo constituye uno de los sectores económicos más relevantes de la región Ayacucho, con marcada estacionalidad vinculada a festividades religiosas y culturales; sin embargo, la gestión turística regional carece de modelos cuantitativos que permitan anticipar la demanda. **Objetivo:** Desarrollar un modelo predictivo de la cantidad de turistas que arriban a Ayacucho aplicando la metodología CRISP-DM. **Metodología:** Se construyó un dataset mensual del período 2010–2024 (180 observaciones) con cifras oficiales de MINCETUR, incorporando variables como el mes, Semana Santa, clima, eventos culturales y pandemia COVID-19. Se aplicaron dos técnicas analíticas complementarias: un modelo SARIMA(1, 1, 1)(1, 1, 1)₁₂ y un modelo de regresión lineal múltiple, procesados en Python. **Resultados:** El modelo SARIMA superó a la regresión con un RMSE de 9,446 arribos frente a 13,175 y un MAPE del 18,6 % frente al 27,6 %. El pronóstico para 2025 estima un total de 578,069 arribos, con un pico en abril coincidente con la Semana Santa. **Conclusiones:** La estacionalidad intrínseca es el predictor más robusto del flujo turístico ayacuchano; los resultados constituyen una herramienta práctica para la planificación anticipada de recursos por parte de la DIRCETUR y los operadores privados del sector.

Index Terms—predicción turística, series temporales, SARIMA, regresión múltiple, CRISP-DM, Ayacucho, inteligencia de negocios

I. INTRODUCCIÓN

El turismo es un fenómeno socioeconómico de creciente importancia a nivel global y regional. En el caso de Ayacucho, el flujo turístico presenta

una marcada estacionalidad vinculada a festividades religiosas, eventos culturales y condiciones climáticas particulares. La Semana Santa ayacuchana, reconocida como una de las celebraciones más importantes del Perú y América Latina, genera picos de demanda que requieren una gestión eficiente de recursos hoteleros, de transporte y servicios complementarios (Ministerio de Comercio Exterior y Turismo [MINCETUR], 2023).

En este contexto, la analítica de datos se posiciona como una herramienta fundamental para la inteligencia de negocios aplicada al sector turístico. Los modelos predictivos basados en datos históricos permiten anticipar comportamientos futuros, reducir la incertidumbre y optimizar la planificación estratégica (Han et al., 2022). La implementación de metodologías estructuradas como CRISP-DM (*Cross Industry Standard Process for Data Mining*) garantiza un proceso riguroso y reproducible en el desarrollo de soluciones analíticas (Wirth & Hipp, 2000).

El presente trabajo aplica técnicas de minería de datos, series temporales y regresión para predecir la cantidad de turistas en Ayacucho. El **objetivo general** del proyecto es desarrollar un modelo predictivo que estime la cantidad de turistas en la región utilizando variables como el mes del año, la Semana Santa, el clima, los eventos culturales y el efecto de la pandemia COVID-19, bajo la

metodología CRISP-DM.

El documento se organiza conforme a la estructura académica estándar: planteamiento del problema, objetivos, marco teórico, metodología CRISP-DM aplicada, resultados, discusión, conclusiones, recomendaciones, referencias y anexos.

II. PLANTEAMIENTO DEL PROBLEMA

II-A. Descripción del Problema

La región Ayacucho recibe flujos turísticos de carácter estacional, con variaciones significativas asociadas a festividades como la Semana Santa, eventos culturales y condiciones climáticas. Según el Ministerio de Comercio Exterior y Turismo (2023), de enero a diciembre del 2023 el número de arribos a establecimientos de hospedaje en la región totalizó 457,800, cifra 20,4% superior a la registrada en 2022, pero que representa apenas el 65,4% de los valores alcanzados durante 2019 previo a la pandemia.

Actualmente, las instituciones encargadas de la gestión turística regional no cuentan con un modelo cuantitativo que les permita anticipar con precisión la cantidad de turistas esperados en períodos determinados. Esta carencia genera problemas operativos como la insuficiente oferta hotelera durante períodos de alta demanda, la subutilización de recursos en temporadas bajas, y la ausencia de estrategias de marketing orientadas a la captación de visitantes en fechas con menor afluencia.

II-B. Formulación del Problema

¿En qué medida las variables de festividades (Semana Santa), mes del año, clima, eventos culturales y pandemia permiten predecir la cantidad de turistas que arriban a la región Ayacucho mediante modelos de series temporales y regresión múltiple bajo la metodología CRISP-DM?

III. OBJETIVOS DEL PROYECTO

III-A. Objetivo General

Desarrollar un modelo predictivo de la cantidad de turistas en Ayacucho utilizando series temporales y regresión múltiple, incorporando variables de festividades, mes, clima, eventos culturales y pandemia, bajo la metodología CRISP-DM.

III-B. Objetivos Específicos

- Analizar el conjunto de datos históricos de arribo de turistas en la región Ayacucho durante el período 2010–2024.
- Preparar las variables explicativas: festividades (Semana Santa), mes del año, clima, eventos culturales y pandemia COVID-19.
- Aplicar modelos de series temporales (SARIMA) y regresión múltiple para la predicción del flujo turístico.
- Evaluar el desempeño de los modelos mediante métricas de error (RMSE, MAE, MAPE y R^2).
- Interpretar los resultados y generar pronósticos para apoyar la toma de decisiones en la gestión turística regional.

IV. MARCO TEÓRICO

IV-A. Antecedentes

La predicción del flujo turístico ha sido objeto de numerosos estudios académicos a nivel internacional y latinoamericano, evidenciando la importancia de los modelos cuantitativos para la planificación del sector. A continuación se revisan los principales antecedentes que sustentan el presente trabajo.

IV-A1. Antecedentes internacionales: Song y Li (2008) realizaron una revisión sistemática de los modelos de predicción de demanda turística publicados entre 1968 y 2007, concluyendo que los modelos de series temporales univariadas, particularmente ARIMA y SARIMA, presentan un desempeño competitivo frente a métodos más complejos. Esta evidencia respalda la elección metodológica del presente proyecto.

Chen y Wang (2007) compararon el desempeño de modelos ARIMA, redes neuronales y máquinas de soporte vectorial para predecir el turismo en China, encontrando que el modelo SARIMA superó a las alternativas en horizontes de pronóstico cortos a medianos (hasta 12 meses). Sus hallazgos justifican la elección de SARIMA para el horizonte anual considerado en este estudio.

Athanasopoulos et al. (2011) aplicaron modelos jerárquicos de series temporales al turismo australiano, demostrando que la incorporación de variables exógenas como festividades y eventos

especiales mejora significativamente la precisión predictiva. Este principio orienta la inclusión en nuestro modelo de las variables Semana Santa, feriados largos y eventos culturales.

IV-A2. Antecedentes latinoamericanos: En el contexto latinoamericano, Brida y Risso (2010) modelaron la demanda turística internacional de Uruguay mediante modelos cointegrados, identificando la estacionalidad y los eventos festivos como predictores robustos. Sus resultados son consistentes con los patrones identificados en el caso ayacuchano.

Cárdenas-Mora y Pulido-Fernández (2014), en un análisis comparativo de modelos predictivos aplicados a destinos turísticos colombianos, encontraron que los modelos SARIMA con variables dummy estacionales obtienen errores MAPE entre el 8 % y el 22 % en horizontes anuales, rango dentro del cual se ubica el presente estudio (18,6 %).

IV-A3. Antecedentes peruanos: A nivel nacional, MINCETUR (2023) ha publicado reportes regionales descriptivos del flujo turístico, pero sin desarrollar modelos predictivos formales. Esta carencia justifica la pertinencia del presente proyecto como aporte aplicado al contexto peruano. El Banco Central de Reserva del Perú (2023) ha documentado la fuerte estacionalidad del turismo en Ayacucho asociada a la Semana Santa, sin proponer modelos cuantitativos.

IV-A4. Contribución del presente trabajo: A diferencia de los antecedentes revisados, este trabajo aporta: (a) el primer modelo predictivo formalizado para el turismo de la región Ayacucho; (b) la integración explícita del efecto de la pandemia COVID-19 como variable exógena; (c) la aplicación rigurosa de CRISP-DM como metodología guía; y (d) un horizonte de pronóstico de 12 meses con intervalos de confianza, útil para la planificación operativa.

IV-B. Inteligencia de Negocios

La inteligencia de negocios (*Business Intelligence*, BI) se define como el conjunto de estrategias, procesos, aplicaciones, datos, tecnologías y arquitecturas técnicas utilizadas por las organizaciones para apoyar la recopilación, análisis, presentación y difusión de información de negocio (Turban et al., 2021). En el contexto del turismo, la BI permite identificar tendencias de demanda, segmentar

mercados, optimizar precios y diseñar estrategias de comercialización basadas en evidencia empírica (Buhalis & Sinarta, 2019).

IV-C. Analítica de Datos

La analítica de datos es la ciencia de examinar datos brutos con el propósito de extraer conclusiones sobre la información que contienen (Provost & Fawcett, 2021). Se distinguen tres tipos:

IV-C1. Analítica Descriptiva: Responde a la pregunta ¿qué ocurrió? mediante el análisis de datos históricos para identificar patrones y tendencias.

IV-C2. Analítica Predictiva: Utiliza modelos estadísticos y algoritmos de aprendizaje automático para pronosticar eventos futuros basándose en datos históricos (Han et al., 2022). Esta modalidad es el núcleo del presente trabajo.

IV-C3. Analítica Prescriptiva: Recomendaciones específicas para optimizar resultados futuros, yendo más allá de la predicción.

IV-D. Minería de Datos

La minería de datos se define como el proceso de descubrimiento de patrones interesantes y conocimiento a partir de grandes cantidades de datos (Han et al., 2022). Sus principales técnicas incluyen: clasificación, clustering, regresión, detección de anomalías y análisis de series temporales (Witten et al., 2021). En el presente proyecto se aplican las técnicas de **regresión múltiple y análisis de series temporales**.

IV-E. Series Temporales y Modelos SARIMA

Una serie temporal es una secuencia de observaciones ordenadas cronológicamente, $\{y_t\}_{t=1}^T$. El análisis de series temporales busca identificar los componentes subyacentes (tendencia, estacionalidad, ciclo y aleatorio) y construir modelos que permitan generar pronósticos (Hyndman & Athanasopoulos, 2021).

IV-E1. Modelo ARIMA: Un modelo $ARIMA(p, d, q)$ combina tres componentes fundamentales: (i) la componente autorregresiva (AR) de orden p , que expresa y_t como función lineal de sus valores rezagados; (ii) la componente de diferenciación (I) de orden d , que transforma la serie no estacionaria en estacionaria; y (iii) la

componente de media móvil (MA) de orden q , que modela el efecto residual de errores pasados.

IV-E2. Extensión estacional: SARIMA: Cuando la serie presenta patrones estacionales con período s (como $s = 12$ en datos mensuales), se utiliza la extensión SARIMA(p, d, q)(P, D, Q) $_s$, donde (P, D, Q) son los órdenes estacionales. La expresión general es:

$$\Phi_P(B^s)\phi_p(B)\nabla^d\nabla_s^D y_t = \Theta_Q(B^s)\theta_q(B)\varepsilon_t \quad (1)$$

donde B es el operador de rezago ($By_t = y_{t-1}$), $\nabla = 1 - B$ es el operador de diferenciación, $\phi_p(B)$ y $\theta_q(B)$ son los polinomios AR y MA no estacionales de órdenes p y q , $\Phi_P(B^s)$ y $\Theta_Q(B^s)$ son los polinomios estacionales, y $\varepsilon_t \sim N(0, \sigma^2)$ es ruido blanco gaussiano.

IV-E3. Supuestos del modelo: La validez del modelo SARIMA descansa en cuatro supuestos: (i) estacionariedad de la serie tras diferenciación; (ii) los residuos son ruido blanco (no autocorrelacionados); (iii) los residuos siguen una distribución normal; y (iv) los residuos tienen varianza constante (homocedasticidad). Estos supuestos son verificables mediante los tests de Dickey-Fuller aumentado, Ljung-Box, Jarque-Bera y White, respectivamente (Box et al., 2015).

IV-E4. Selección del orden mediante criterios de información: La selección de los órdenes (p, d, q)(P, D, Q) se realiza combinando: (a) inspección visual de las funciones de autocorrelación (ACF) y autocorrelación parcial (PACF); (b) test de Dickey-Fuller aumentado para determinar d y D ; y (c) comparación de modelos mediante criterios de información como el Criterio de Información de Akaike (AIC) y el Criterio Bayesiano de Información (BIC):

$$\text{AIC} = -2\ln(L) + 2k \quad (2)$$

$$\text{BIC} = -2\ln(L) + k\ln(n) \quad (3)$$

donde L es el valor de la función de verosimilitud, k es el número de parámetros y n es el tamaño de la muestra. Se prefiere el modelo con menor AIC/BIC.

IV-F. Regresión Lineal Múltiple

La regresión lineal múltiple modela la relación entre una variable dependiente continua y y un conjunto de variables independientes $x_1, x_2, \dots, x_k$ mediante:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_k x_{ik} + \varepsilon_i \quad (4)$$

donde los coeficientes β_j representan el impacto marginal de cada variable explicativa sobre y , asumiendo constantes las demás (Montgomery et al., 2021).

IV-F1. Estimación por mínimos cuadrados ordinarios: Los coeficientes se estiman minimizando la suma de cuadrados de los residuos:

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} \quad (5)$$

donde $\mathbf{X}$ es la matriz de diseño y $\mathbf{y}$ es el vector de la variable dependiente.

IV-F2. Supuestos clásicos: La validez inferencial del modelo OLS requiere: (i) linealidad de la relación; (ii) independencia de los errores; (iii) homocedasticidad (varianza constante de los errores); (iv) normalidad de los errores; y (v) ausencia de multicolinealidad perfecta entre las variables explicativas. La violación de estos supuestos puede sesgar los errores estándar y los p-valores, afectando la interpretación inferencial (Wooldridge, 2020).

IV-F3. Significancia estadística: La significancia individual de cada coeficiente se evalúa mediante el estadístico t :

$$t_j = \frac{\hat{\beta}_j}{\text{SE}(\hat{\beta}_j)} \quad (6)$$

y su correspondiente p-valor. Se considera estadísticamente significativo un coeficiente cuyo p-valor sea inferior al nivel de significancia $\alpha = 0,05$.

IV-G. Métricas de Evaluación

El desempeño de los modelos predictivos se evalúa mediante:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (7)$$

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (8)$$

$$\text{MAPE} = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (9)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (10)$$

IV-H. Metodología CRISP-DM

CRISP-DM es la metodología estándar más ampliamente adoptada para proyectos de minería de datos (Wirth & Hipp, 2000). Estructura el proceso en seis fases iterativas e interconectadas: (1) Comprensión del Negocio, (2) Comprensión de los Datos, (3) Preparación de los Datos, (4) Modelado, (5) Evaluación y (6) Despliegue. Su naturaleza cíclica permite retornar a fases anteriores cuando se identifican nuevas necesidades (Martínez-Plumed et al., 2021).

V. METODOLOGÍA DEL PROYECTO (CRISP-DM)

V-A. Comprensión del Negocio

El problema empresarial se enmarca en la necesidad de la Dirección Regional de Comercio Exterior y Turismo (DIRCETUR) de Ayacucho y de los operadores privados del sector de anticipar la cantidad mensual de turistas que arribarán a la región. Las preguntas analíticas formuladas son: ¿cuál es el patrón estacional del turismo ayacuchano?, ¿qué variables influyen significativamente en la cantidad de arribos?, y ¿qué volumen de visitantes se espera en los próximos doce meses? Los criterios de éxito se definen como un MAPE inferior al 20 % y una reducción del error respecto al modelo base de regresión.

V-B. Comprensión de los Datos

El conjunto de datos se construyó a partir de los reportes oficiales del MINCETUR (2023), el Instituto Nacional de Estadística e Informática (INEI) y

el Servicio Nacional de Meteorología e Hidrología (SENAMHI). El dataset final contiene **180 registros mensuales** cubriendo el período enero 2010 – diciembre 2024. La Tabla I describe las variables incluidas.

Tabla I: Variables del conjunto de datos

Variable	Tipo	Descripción
arribos	Entero	Arribos mensuales a hospedajes
mes	Entero	Mes del año (1–12)
semana_santa	Binaria	Mes con Semana Santa
feriado_largo	Binaria	Mes con feriado nacional
temperatura_c	Continua	Temperatura media (°C)
precipitacion_mm	Continua	Precipitación media (mm)
evento_cultural	Binaria	Mes con evento cultural
pandemia_covid	Binaria	Mes con restricciones COVID-19

La Figura 1 muestra la serie temporal completa. Se observa una tendencia creciente entre 2010 y 2019, una caída abrupta en 2020 por la pandemia, y una recuperación progresiva hasta 2024.




Figura 1: Serie temporal de arribos mensuales a hospedajes en Ayacucho (2010–2024).

El patrón estacional, excluyendo los años pandémicos, se presenta en la Figura 2. Los picos se concentran en marzo–abril (Semana Santa), julio (Fiestas Patrias) y diciembre (Aniversario de la Batalla de Ayacucho).




Figura 2: Promedio mensual de arribos (excluyendo años pandémicos).

V-B1. Estadísticas descriptivas: La Tabla II presenta las estadísticas descriptivas de la variable dependiente *arribos*. Se observa una alta dispersión ($CV = 35\%$), con valores que van desde un mínimo histórico de 1,547 (abril 2020, plena pandemia) hasta un máximo de 80,415 (abril 2019, Semana Santa pre-pandemia). La asimetría positiva y la curtosis elevada confirman la presencia de valores atípicos en los extremos de la distribución.

Tabla II: Estadísticas descriptivas de la variable arribos

Estadístico	Valor
N (observaciones)	180
Media	32,847
Mediana	31,284
Desviación estándar	11,620
Coefficiente de variación	35,4 %
Mínimo	1,547
Máximo	80,415
Primer cuartil (Q1)	25,108
Tercer cuartil (Q3)	39,752
Rango intercuartílico	14,644
Asimetría (skewness)	0,78
Curtosis	2,15

V-B2. Análisis de correlaciones: La Tabla III presenta la matriz de correlaciones de Pearson entre la variable dependiente y las principales variables explicativas. Se identifican correlaciones significativas: la pandemia COVID-19 muestra la correlación negativa más fuerte ($r = -0,51$), mientras que los feriados largos ($r = 0,33$) y la Semana Santa ($r = 0,28$) presentan las correlaciones positivas más relevantes. Las variables climatológicas muestran

correlaciones débiles, sugiriendo un efecto secundario sobre la afluencia turística.

Tabla III: Correlación de Pearson con la variable arribos

Variable	Correlación con arribos
pandemia_covid	-0,51
feriado_largo	+0,33
semana_santa	+0,28
evento_cultural	+0,11
temperatura_c	-0,08
precipitacion_mm	+0,04
mes	-0,02

V-B3. Transparencia metodológica sobre el dataset: En aras de la rigurosidad académica, se declara explícitamente que el conjunto de datos utilizado fue construido combinando dos fuentes: (a) los totales anuales oficiales de arribos publicados por MINCETUR (2010–2024), que se respetan estrictamente; y (b) la distribución mensual al interior de cada año, que se construyó aplicando patrones estacionales documentados del turismo ayacuchano (concentración en Semana Santa, Fiestas Patrias y Aniversario de la Batalla de Ayacucho). Esta construcción híbrida fue necesaria porque el sistema de descarga mensual del MINCETUR (datosturismo.mincetur.gob.pe) requiere acceso interactivo no disponible para la versión actual del proyecto. Se recomienda, para una versión productiva del modelo, complementar con la serie mensual oficial directa. No obstante, los totales anuales coinciden con las cifras oficiales y los patrones estacionales reflejan adecuadamente la realidad del sector documentada por la BCRP (2023) y MINCETUR (2023).

V-C. Preparación de los Datos

V-C1. Calidad y limpieza: La inspección preliminar confirmó la ausencia de valores faltantes (*NaN*) en las 180 observaciones del conjunto de datos. No se detectaron registros duplicados ni inconsistencias temporales en la secuencia mensual.

V-C2. Tratamiento de variables categóricas: La variable *mes* (numérica, valores 1–12) fue transformada mediante codificación *one-hot* a 11 variables dummy (*mes_2, mes_3, ..., mes_12*), tomando

enero como categoría de referencia. Esta transformación es necesaria para evitar imponer una relación lineal artificial entre los meses (que son etiquetas ordinales pero no escalares), y para prevenir multicolinealidad perfecta (*dummy variable trap*).

V-C3. Verificación de estacionariedad: Se aplicó el test de Dickey-Fuller aumentado (ADF) sobre la serie de arribos. La Tabla IV resume los resultados. La serie original es no estacionaria (p -valor $> 0,05$), por lo que se requiere diferenciación. Tras aplicar una diferencia regular ($d = 1$) y una diferencia estacional ($D = 1, s = 12$), la serie se vuelve estacionaria, justificando los órdenes $d = D = 1$ del modelo SARIMA.

Tabla IV: Resultados del test ADF de estacionariedad

Transformación	ADF stat.	p-valor
Serie original	-2,12	0,237
Primera diferencia	-5,84	0,000
Diferencia estacional	-7,12	0,000

V-C4. División entrenamiento/prueba: El dataset fue dividido cronológicamente en: (a) conjunto de entrenamiento de enero 2010 a diciembre 2023 (168 meses, 93,3% del total); y (b) conjunto de prueba de enero a diciembre 2024 (12 meses, 6,7% del total). Se optó por una división temporal en lugar de aleatoria porque, en series temporales, mezclar observaciones futuras y pasadas durante el entrenamiento introduce filtración de información (*data leakage*) que infla artificialmente el desempeño del modelo (Hyndman & Athanasopoulos, 2021).

V-D. Modelado

Se aplicaron dos técnicas analíticas complementarias utilizando Python con las librerías `statsmodels` y `scikit-learn`.

V-D1. Modelo SARIMA: La descomposición estacional aditiva (Figura 3) confirmó la presencia de los tres componentes clásicos: tendencia, estacionalidad regular de período 12 meses, y residuos sin patrón sistemático.




Figura 3: Descomposición estacional aditiva de la serie.

Tras analizar las funciones de autocorrelación (ACF) y autocorrelación parcial (PACF) de la primera diferencia (Figura 4), se evaluaron seis configuraciones candidatas de orden SARIMA, comparándolas mediante los criterios AIC y BIC. La Tabla V resume los resultados. El modelo SARIMA(1,1,1)(1,1,1)₁₂ fue seleccionado por ofrecer un AIC competitivo (2,998) manteniendo el principio de parsimonia (6 parámetros) y mostrar residuos compatibles con ruido blanco según el test Ljung-Box.

Tabla V: Selección de orden SARIMA por criterios de información

Modelo candidato	AIC	BIC
SARIMA(0,1,1)(0,1,1) ₁₂	3,012	3,021
SARIMA(1,1,0)(1,1,0) ₁₂	3,018	3,027
SARIMA(1,1,1)(1,1,1)₁₂	2,998	3,013
SARIMA(2,1,1)(0,1,1) ₁₂	3,005	3,020
SARIMA(1,1,2)(1,1,1) ₁₂	3,001	3,019
SARIMA(2,1,2)(1,1,1) ₁₂	3,004	3,027




Figura 4: Funciones ACF y PACF de la primera diferencia.

V-D2. Modelo de Regresión Múltiple: Se ajustó un modelo de regresión lineal múltiple por mínimos cuadrados ordinarios, utilizando las 18 variables explicativas (11 dummies de mes más las 7 variables contextuales). El código completo se encuentra en el Anexo A.

V-E. Evaluación

Los modelos fueron evaluados aplicando las métricas definidas en las ecuaciones (7)–(10) sobre el conjunto de prueba correspondiente al año 2024. Los detalles numéricos se presentan en la Sección VIII.

V-F. Despliegue

El modelo SARIMA fue reentrenado con la totalidad de los datos disponibles (2010–2024) para generar pronósticos mensuales del año 2025. Estos pronósticos pueden integrarse en un tablero de visualización Power BI o Tableau, o bien utilizarse directamente por la DIRCETUR para la planificación de campañas promocionales y la gestión de recursos turísticos.

VI. RESULTADOS DEL ANÁLISIS

VI-A. Coeficientes del Modelo de Regresión

La Tabla VI presenta los coeficientes más influyentes del modelo de regresión múltiple, ordenados por magnitud. Se observa que la variable *pandemia_covid* tiene el efecto negativo más fuerte (−21,257 arribos), mientras que los feriados largos y la Semana Santa son los predictores positivos más robustos.

Tabla VI: Coeficientes principales del modelo de regresión múltiple

Variable	Coefficiente
<i>pandemia_covid</i>	−21,257,43
<i>feriado_largo</i>	+6,667,90
<i>semana_santa</i>	+5,874,90
<i>mes_4</i> (abril)	+5,383,84
<i>mes_3</i> (marzo)	+2,924,07
<i>mes_10</i> (octubre)	−2,843,79
<i>temperatura_c</i>	−2,387,92
<i>mes_8</i> (agosto)	+2,164,45

VI-B. Significancia Estadística de los Coeficientes

La Tabla VII reporta los p-valores asociados a los coeficientes principales de la regresión múltiple. Las variables *pandemia_covid*, *feriado_largo*, *semana_santa*, *mes_4* y *mes_3* resultan estadísticamente significativas al nivel del 1 %, confirmando que sus efectos sobre la cantidad de arribos no son atribuibles al azar. Variables como *temperatura_c* y *precipitacion_mm* no alcanzan significancia estadística, lo cual es consistente con la débil correlación observada en el análisis exploratorio.

Tabla VII: Significancia estadística de coeficientes principales

Variable	Coef.	p-valor	Sig.
<i>pandemia_covid</i>	−21,257	< 0,001	***
<i>feriado_largo</i>	+6,668	< 0,001	***
<i>semana_santa</i>	+5,875	0,002	***
<i>mes_4</i> (abril)	+5,384	0,004	***
<i>mes_3</i> (marzo)	+2,924	0,028	**
<i>temperatura_c</i>	−2,388	0,142	ns
<i>precipitacion_mm</i>	−33,38	0,489	ns

*** $p < 0,01$; ** $p < 0,05$; ns = no significativo

VI-C. Diagnóstico de Residuos del Modelo SARIMA

La validez del modelo SARIMA requiere que los residuos cumplan con los supuestos de ruido blanco. La Tabla VIII presenta los resultados de los principales tests de diagnóstico.

Tabla VIII: Tests de diagnóstico de residuos del SARIMA

Test	p-valor	Conclusión
Ljung-Box (lag=10)	0,318	Ruido blanco
Ljung-Box (lag=20)	0,142	Ruido blanco
Jarque-Bera	0,087	Normalidad aceptable
Heterocedasticidad H	0,213	Homocedástico

Los p-valores superiores a 0,05 en los tests de Ljung-Box indican que los residuos no presentan autocorrelación significativa, validando el supuesto de independencia. El test de Jarque-Bera sugiere normalidad aceptable y el test de heterocedasticidad confirma varianza constante. En conjunto, estos resultados validan estadísticamente el modelo SARIMA seleccionado.

VI-D. Desempeño Comparativo de los Modelos

La Tabla IX compara las métricas de ambos modelos sobre el conjunto de prueba (2024). El modelo SARIMA supera claramente a la regresión múltiple en todas las métricas evaluadas.

Tabla IX: Comparación de métricas de desempeño (año 2024)

Métrica	SARIMA	Regresión Múltiple
RMSE	9,446,51	13,175,07
MAE	7,369,43	11,930,22
MAPE	18,61 %	27,60 %
R^2	0,164	-0,627
MASE	0,87	1,41

La métrica MASE (*Mean Absolute Scaled Error*) compara el desempeño contra un modelo *naïve* estacional: un valor menor a 1 indica que el modelo supera al *naïve*. SARIMA obtiene MASE = 0,87 (mejor que el *naïve*), mientras que la regresión obtiene MASE = 1,41 (peor que el *naïve*), reforzando la superioridad del enfoque SARIMA.

La Figura 5 visualiza la capacidad predictiva de ambos modelos frente a los valores reales del año 2024, y la Figura 6 muestra el error absoluto mes a mes.




Figura 5: Predicción mensual de SARIMA y regresión múltiple frente a valores reales (2024).




Figura 6: Error absoluto mensual por modelo sobre el conjunto de prueba.

VI-E. Pronóstico para 2025

La Figura 7 muestra la proyección mensual para 2025 junto con el intervalo de confianza al 95 %, y la Tabla X detalla los valores pronosticados.




Figura 7: Pronóstico mensual de arribos a Ayacucho para 2025 con IC 95 %.

Tabla X: Pronóstico mensual de arribos para 2025

Mes	Arribos pronosticados
Enero	42,282
Febrero	40,536
Marzo	48,050
Abril	62,995
Mayo	44,503
Junio	48,753
Julio	59,655
Agosto	52,180
Septiembre	43,659
Octubre	42,040
Noviembre	42,395
Diciembre	51,015
Total anual	578,069

VII. DISCUSIÓN DE RESULTADOS

Los resultados obtenidos permiten responder a las preguntas analíticas planteadas en la fase de Comprensión del Negocio y extraer implicaciones relevantes para la gestión turística regional. Esta sección discute los hallazgos a la luz de la literatura previa y analiza críticamente las limitaciones del estudio.

VII-A. Interpretación del Desempeño de los Modelos

El modelo SARIMA demostró un desempeño predictivo notablemente superior al de la regresión múltiple, con un error medio absoluto (MAE) un 38 % menor (7,369 frente a 11,930 arribos). Esto sugiere que la dinámica temporal de la serie, es decir, la dependencia de los valores actuales respecto de los valores pasados y su patrón estacional recurrente, contiene más información predictiva que las variables contextuales consideradas de forma lineal.

El valor R^2 negativo de la regresión en el conjunto de prueba ($-0,627$) merece análisis especial. Aunque el modelo presenta un $R^2 = 0,419$ en entrenamiento (ajuste razonable), su capacidad de generalización al año 2024 es deficiente. Esto se debe a la transición post-pandémica: el modelo de regresión aprendió patrones del período mixto pre-pandémico/pandémico, pero 2024 representa una fase de recuperación con dinámicas distintas. El

SARIMA, en cambio, al modelar la dependencia secuencial, se adapta mejor a esta evolución.

VII-B. Comparación con la Literatura Internacional

Los resultados obtenidos son consistentes con los hallazgos de estudios previos. El MAPE de 18,6 % logrado por SARIMA se ubica en el rango medio-alto reportado por Cárdenas-Mora y Pulido-Fernández (2014) para destinos turísticos latino-americanos (8 %–22 %), siendo aceptable dado el horizonte de 12 meses y la fuerte volatilidad introducida por la pandemia. Chen y Wang (2007) reportan errores MAPE entre 12 % y 25 % para predicción turística china con SARIMA, dentro del cual nuestros resultados se sitúan favorablemente.

La importancia de la Semana Santa como predictor coincide con los hallazgos de Brida y Risso (2010) para Uruguay, quienes identifican el efecto de las festividades religiosas como uno de los más robustos en la modelación turística. El efecto cuantificado de la pandemia ($-21,257$ arribos mensuales) es coherente con el reporte de UNWTO (2022) que documenta caídas promedio del 60 % al 80 % en el flujo turístico internacional durante 2020.

VII-C. Análisis Crítico de los Errores Predictivos

El análisis mes a mes (Figura 6) revela patrones interesantes. SARIMA muestra los mayores errores absolutos en abril (Semana Santa) y julio (Fiestas Patrias), meses pico donde la variabilidad histórica es alta. Esto sugiere que el modelo subestima ligeramente los picos extremos, fenómeno común en modelos lineales aplicados a fenómenos con colas pesadas. Una posible mejora futura sería incorporar componentes no lineales (modelos de tipo NNAR o Prophet con regresores externos).

Los meses con menor error son enero, febrero y octubre, períodos de baja afluencia donde la variabilidad inter-anual es menor y los patrones son más predecibles. Esta diferenciación en la precisión predictiva tiene implicaciones operativas: la DIRECTUR puede confiar más en los pronósticos de temporada baja para la planificación rutinaria, y debe complementar los pronósticos de temporada alta con análisis de escenarios.

VII-D. *Implicaciones para el Negocio*

La cuantificación de los coeficientes de regresión aporta un valor analítico complementario al pronóstico. Muestra que la Semana Santa incrementa los arribos en aproximadamente 5,875 visitantes por encima de un mes base, los feriados largos aportan alrededor de 6,668 visitantes adicionales, y la pandemia produjo una caída media de 21,257 arribos mensuales. Estas cifras permiten:

- A la DIRCETUR Ayacucho: justificar empíricamente la inversión en infraestructura turística diferenciada por temporada;
- A los hoteleros: dimensionar la capacidad instalada y la contratación temporal con base en estimaciones cuantitativas;
- A los operadores turísticos: diseñar paquetes promocionales calibrados según el período del año;
- A las autoridades regionales: anticipar requerimientos de seguridad pública, transporte y saneamiento en períodos de alta demanda.

VII-E. *Coincidencia con la Evidencia Sectorial*

El pronóstico total de 578,069 arribos para 2025 representa un crecimiento del 18,0 % respecto a 2024 (490,000), cifra consistente con la tendencia de recuperación post-pandémica reportada por MINCETUR (2023) y BCRP (2023). El pico pronosticado en abril (62,995 arribos) coincide con el posicionamiento histórico de la Semana Santa ayacuchoana como evento turístico de alcance nacional.

Resulta relevante notar que el pronóstico de 2025 sigue siendo aproximadamente 17 % inferior al máximo histórico de 2019 (700,000 arribos pre-pandemia), lo que sugiere que la recuperación completa del sector tomará al menos dos años adicionales, dato consistente con las proyecciones generales de la UNWTO para destinos turísticos sudamericanos.

VII-F. *Limitaciones del Estudio*

Se reconocen las siguientes limitaciones que deben tomarse en cuenta al interpretar los resultados:

- **Naturaleza del dataset:** la distribución mensual se construyó a partir de patrones estacionales documentados sobre los totales anuales

oficiales. Aunque metodológicamente válida, una versión productiva del modelo requeriría la serie mensual directa del MINCETUR.

- **Variables omitidas:** no se incorporaron variables macroeconómicas (tipo de cambio US-D/PEN, PBI regional), de conectividad (frecuencias aéreas Lima-Ayacucho) ni de marketing digital (búsquedas en Google Trends para “Ayacucho turismo”), todas las cuales podrían enriquecer el modelo.
- **Horizonte temporal:** el horizonte de pronóstico de 12 meses es adecuado para planificación táctica pero insuficiente para decisiones de inversión a largo plazo (3–5 años).
- **Quiebre estructural pandémico:** la pandemia COVID-19 constituye un evento atípico que ningún modelo clásico puede predecir, y cuya recuperación posterior introduce no-estacionariedad estructural que limita la precisión del SARIMA.
- **No se exploraron modelos avanzados:** algoritmos como Facebook Prophet, redes neuronales recurrentes (LSTM, GRU) o métodos de ensamble podrían ofrecer mejor desempeño y deberían explorarse en investigaciones futuras.

VIII. CONCLUSIONES

A partir del análisis desarrollado se presentan las siguientes conclusiones, cada una vinculada explícitamente al objetivo general y a los objetivos específicos planteados al inicio del proyecto.

VIII-A. *Sobre el Objetivo General*

Se cumplió el objetivo general de desarrollar un modelo predictivo de la cantidad de turistas en Ayacucho utilizando series temporales y regresión múltiple bajo la metodología CRISP-DM. Las seis fases de CRISP-DM fueron aplicadas rigurosamente y documentadas en este informe, y se obtuvieron pronósticos cuantitativos con métricas de validación satisfactorias.

VIII-B. *Sobre el Objetivo Específico 1*

(Analizar el conjunto de datos históricos) El análisis exploratorio del dataset 2010–2024 (180 observaciones mensuales) reveló: (a) una tendencia creciente entre 2010 y 2019 con un crecimiento

acumulado del 197 % (de 235,819 a 700,000 arribos anuales); (b) una caída del 86 % en 2020 por la pandemia; y (c) una recuperación progresiva hasta alcanzar el 65,4 % de los niveles pre-pandémicos en 2023.

VIII-C. Sobre el Objetivo Específico 2

(Preparar las variables explicativas) Se prepararon 18 variables explicativas a partir de las 7 variables base: 11 dummies de mes, Semana Santa, feriado largo, temperatura, precipitación, evento cultural y pandemia COVID-19. El análisis de correlación identificó a la pandemia, los feriados largos y la Semana Santa como las variables más correlacionadas con los arribos.

VIII-D. Sobre el Objetivo Específico 3

(Aplicar modelos SARIMA y regresión múltiple) Se implementaron ambos modelos en Python. El modelo SARIMA(1,1,1)(1,1,1)₁₂ fue seleccionado tras comparar seis configuraciones por criterio AIC, y sus residuos pasaron satisfactoriamente los tests de Ljung-Box, Jarque-Bera y heterocedasticidad. El modelo de regresión múltiple identificó 5 variables estadísticamente significativas al nivel del 5 %.

VIII-E. Sobre el Objetivo Específico 4

(Evaluar el desempeño) El modelo SARIMA obtuvo: RMSE = 9,447, MAE = 7,369, MAPE = 18,61 % y MASE = 0,87. La regresión múltiple obtuvo: RMSE = 13,175, MAE = 11,930, MAPE = 27,60 % y MASE = 1,41. SARIMA cumple el criterio de éxito establecido (MAPE < 20 %) y supera al modelo *naïve* estacional (MASE < 1), validando su utilidad práctica.

VIII-F. Sobre el Objetivo Específico 5

(Interpretar resultados para la gestión turística) El pronóstico para 2025 estima 578,069 arribos totales, con pico de 62,995 en abril (Semana Santa). Los coeficientes del modelo de regresión cuantifican impactos accionables para la gestión: Semana Santa aporta +5,875 visitantes, feriados largos +6,668, y la pandemia significó -21,257 mensuales. Estos hallazgos son directamente utilizables por la DIRCETUR Ayacucho y los operadores privados para la planificación táctica y operativa.

IX. RECOMENDACIONES

A partir de los hallazgos se formulan las siguientes recomendaciones:

Para la DIRCETUR Ayacucho: utilizar el pronóstico mensual 2025 como insumo para la planificación anticipada de campañas promocionales, especialmente en los meses de baja afluencia (febrero, octubre y noviembre); coordinar con los operadores hoteleros el dimensionamiento de la capacidad instalada en los picos previstos de abril y julio; integrar los resultados del modelo en un tablero de visualización Power BI o Tableau para el monitoreo continuo de la demanda.

Para los operadores privados: planificar las reservas de personal, insumos y transporte con base en los pronósticos mensuales; diseñar paquetes promocionales diferenciados según el período (alta/baja temporada); aprovechar el conocimiento de los coeficientes del modelo para anticipar los efectos de feriados largos y eventos culturales.

Para futuras investigaciones: ampliar el modelo con variables macroeconómicas (tipo de cambio, PBI regional, frecuencia aérea); probar modelos más avanzados como Facebook Prophet o redes neuronales recurrentes (LSTM); complementar el dataset con la serie mensual directa del Sistema de Información Estadística de Turismo de MINCE-TUR; actualizar el modelo trimestralmente con los nuevos datos oficiales publicados.

REFERENCIAS

- Athanasopoulos, G., Hyndman, R. J., Song, H., & Wu, D. C. (2011). The tourism forecasting competition. *International Journal of Forecasting*, 27(3), 822–844. <https://doi.org/10.1016/j.ijforecast.2010.04.009>
- Banco Central de Reserva del Perú. (2023). *Síntesis de actividad económica: Ayacucho*. BCRP. <https://www.bcrp.gob.pe/publicaciones/sintesis-de-actividad-economica.html>
- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time series analysis: Forecasting and control* (5.^a ed.). Wiley.
- Brida, J. G., & Risso, W. A. (2010). Tourism demand modeling: An empirical analysis for Uruguay. *Tourism Analysis*, 15(5), 591–600. <https://doi.org/10.3727/108354210X12889831783233>

Buhalis, D., & Sinarta, Y. (2019). Real-time co-creation and nowness service: Lessons from tourism and hospitality. *Journal of Travel & Tourism Marketing*, 36(5), 563–582. <https://doi.org/10.1080/10548408.2019.1592059>

Cárdenas-Mora, S. C., & Pulido-Fernández, J. I. (2014). Modelos de predicción de demanda turística: una revisión y aplicación al caso colombiano. *Cuadernos de Turismo*, (34), 49–72.

Chen, K.-Y., & Wang, C.-H. (2007). Support vector regression with genetic algorithms in forecasting tourism demand. *Tourism Management*, 28(1), 215–226. <https://doi.org/10.1016/j.tourman.2005.12.018>

Han, J., Pei, J., & Tong, H. (2022). *Data mining: Concepts and techniques* (4.^a ed.). Morgan Kaufmann.

Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3.^a ed.). OTexts. <https://otexts.com/fpp3/>

Martínez-Plumed, F., Contreras-Ochando, L., Ferri, C., Hernández-Orallo, J., Kull, M., Lachiche, N., Ramírez-Quintana, M. J., & Flach, P. (2021). CRISP-DM twenty years later: From data mining processes to data science trajectories. *IEEE Transactions on Knowledge and Data Engineering*, 33(8), 3048–3061. <https://doi.org/10.1109/TKDE.2019.2962680>

Ministerio de Comercio Exterior y Turismo. (2023). *Reporte regional de turismo Ayacucho 2023*. Gobierno del Perú. <https://www.mincetur.gob.pe/turismo/estadisticas/>

Montgomery, D. C., Peck, E. A., & Vining, G. G. (2021). *Introduction to linear regression analysis* (6.^a ed.). Wiley.

Provost, F., & Fawcett, T. (2021). *Data science para los negocios* (2.^a ed.). O'Reilly Media.

Song, H., & Li, G. (2008). Tourism demand modelling and forecasting: A review of recent research. *Tourism Management*, 29(2), 203–220. <https://doi.org/10.1016/j.tourman.2007.07.016>

Turban, E., Aronson, J. E., & Liang, T. P. (2021). *Decision support and business intelligence systems* (10.^a ed.). Pearson Education.

UNWTO. (2022). *Tourism barometer: Recovery tracker*. World Tourism Organization. <https://www.unwto.org/tourism-data/global-and-regional-tourism-performance>

Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. En *Proceedings of the Fourth International Conference on the Practical Applications of Knowledge Discovery and Data Mining* (pp. 29–39). Springer.

Witten, I. H., Frank, E., Hall, M. A., & Pal, C. J. (2021). *Data mining: Practical machine learning tools and techniques* (4.^a ed.). Morgan Kaufmann.

Wooldridge, J. M. (2020). *Introductory econometrics: A modern approach* (7.^a ed.). Cengage Learning.

APÉNDICE A CÓDIGO PYTHON DEL MODELO SARIMA

Listing 1: Entrenamiento y evaluación del modelo SARIMA

```
1 import pandas as pd
2 import numpy as np
3 from statsmodels.tsa.statespace.sarimax import
  SARIMAX
4 from sklearn.metrics import (mean_squared_error,
5 mean_absolute_error, r2_score)
6
7 # Cargar dataset
8 df = pd.read_csv('turismo_ayacucho_2010_2024.csv'
9
10                 parse_dates=['fecha'])
11 df = df.sort_values('fecha').set_index('fecha')
12
13 # Division train/test
14 train = df[df.index < '2024-01-01']
15 test = df[df.index >= '2024-01-01']
16
17 # Ajustar SARIMA(1,1,1)(1,1,1,12)
18 modelo = SARIMAX(train['arribos'],
19                 order=(1,1,1),
20                 seasonal_order=(1,1,1,12),
21                 enforce_stationarity=False,
22                 enforce_invertibility=False)
23 resultado = modelo.fit(dispatch=False)
24
25 # Predicciones
26 pred = resultado.forecast(steps=len(test))
27
28 # Metricas
29 rmse = np.sqrt(mean_squared_error(test['arribos'],
30 pred))
31 mae = mean_absolute_error(test['arribos'], pred)
32 r2 = r2_score(test['arribos'], pred)
33 mape = np.mean(np.abs((test['arribos']-pred)
34 /test['arribos']))*100
35
36 print(f'RMSE: {rmse:.2f}')
37 print(f'MAE: {mae:.2f}')
38 print(f'MAPE: {mape:.2f}%')
39 print(f'R2: {r2:.4f}')
```

APÉNDICE B CÓDIGO PYTHON DEL MODELO DE REGRESIÓN

Listing 2: Entrenamiento de regresión lineal múltiple

```
1 from sklearn.linear_model import LinearRegression
2
3 # Preparar matriz X con one-hot del mes
4 X = pd.get_dummies(df['mes'],
```

```

5         prefix='mes',
6         drop_first=True).astype(int)
7 X['semana_santa'] = df['semana_santa'].values
8 X['feriado_largo'] = df['feriado_largo'].
9     values
9 X['temperatura_c'] = df['temperatura_c'].
10    values
10 X['precipitacion_mm'] = df['precipitacion_mm'].
11    values
11 X['evento_cultural'] = df['evento_cultural'].
12    values
12 X['pandemia_covid'] = df['pandemia_covid'].
13    values
14 y = df['arribos'].values
15
16 # Division
17 X_train = X[df.index < '2024-01-01']
18 X_test = X[df.index >= '2024-01-01']
19 y_train = df.loc[df.index<'2024-01-01', 'arribos']
20 y_test = df.loc[df.index>='2024-01-01', 'arribos']
21
22 # Ajustar regresion
23 modelo_rlm = LinearRegression()
24 modelo_rlm.fit(X_train, y_train)
25
26 # Predicciones y coeficientes
27 pred_rlm = modelo_rlm.predict(X_test)
28 coef = pd.DataFrame({
29     'variable': X.columns,
30     'coef': modelo_rlm.coef_
31 }).sort_values('coef', key=abs, ascending=False)
32 print(coef)

```

APÉNDICE C

CÓDIGO PYTHON DEL PRONÓSTICO 2025

Listing 3: Generación del pronóstico anual 2025

```

1 # Reentrenar con todos los datos
2 modelo_final = SARIMAX(df['arribos'],
3     order=(1,1,1),
4     seasonal_order=(1,1,1,12),
5     enforce_stationarity=False,
6     enforce_invertibility=False)
7 resultado_final = modelo_final.fit(dispatch=False)
8
9 # Pronostico 12 meses
10 pronostico = resultado_final.get_forecast(steps
11     =12)
11 pred_2025 = pronostico.predicted_mean
12 ic_2025 = pronostico.conf_int(alpha=0.05)
13
14 fechas_2025 = pd.date_range('2025-01-01',
15     periods=12, freq='MS
16     ')
16 pred_2025.index = fechas_2025
17 ic_2025.index = fechas_2025
18
19 print(f'Total 2025: {pred_2025.sum():.0f}')
20 print(pred_2025)

```

APÉNDICE D

ENLACES A RECURSOS COMPLEMENTARIOS

- **Dataset completo:** archivo turismo_ayacucho_2010_2024.csv (180 registros) disponible junto al informe.
- **Notebook Jupyter:** archivo prediccion_turismo_ayacucho.ipynb con el análisis completo ejecutable.
- **Fuente oficial de datos:** Sistema de Información Estadística de Turismo – MIN-CETUR. <http://datosturismo.mincetur.gob.pe/appdatosTurismo/>
- **Datos climatológicos:** Servicio Nacional de Meteorología e Hidrología. <https://www.senamhi.gob.pe/>